



## **PROYECTO ARIMA**

**Universidad Autónoma de Querétaro**

**Yañez Omaña Emilio**

## **Proyecto : Análisis de Predicción de Rendimientos de NVIDIA Usando ARIMA**

### **Introducción al Modelo ARIMA**

El modelo ARIMA (Autoregressive Integrated Moving Average) es una herramienta estadística ampliamente utilizada para modelar y predecir series temporales. Su principal ventaja radica en su capacidad para capturar patrones de dependencia temporal en datos, como tendencias, estacionalidades y fluctuaciones aleatorias. El modelo ARIMA se compone de tres componentes principales:

1. **Autoregresión (AR):** Representa la dependencia lineal entre un valor actual y sus valores pasados.
2. **Diferenciación (I):** Permite transformar una serie no estacionaria en estacionaria eliminando tendencias.
3. **Media Móvil (MA):** Modela la relación entre un valor actual y el error de predicción de periodos pasados.

### **Metodología**

Para este proyecto, se utilizó el modelo ARIMA para predecir el precio ajustado de cierre de las acciones de NVIDIA (NVDA). Los pasos principales del análisis fueron los siguientes:

1. **Descarga de Datos:** Se obtuvieron datos históricos del precio ajustado de cierre de NVIDIA desde Yahoo Finance. El periodo analizado abarcó desde 2015 hasta 2024.
2. **Exploración de Datos:** Se realizó una visualización inicial para identificar patrones generales en la serie temporal, como tendencias o cambios significativos.
3. **Prueba de Estacionariedad:** Utilizamos la prueba de Dickey-Fuller aumentada (ADF) para determinar si la serie era estacionaria. Una serie es estacionaria si sus propiedades estadísticas (media y varianza) no cambian con el tiempo.

4. **Transformación de la Serie:** Dado que la serie no era estacionaria, se aplicaron diferencias para estabilizar la media y eliminar tendencias.
5. **Identificación de Parámetros:** Se emplearon gráficos de la función de autocorrelación (ACF) y autocorrelación parcial (PACF) para identificar los órdenes del modelo ARIMA más apropiados.
6. **Entrenamiento del Modelo:** Se ajustó un modelo ARIMA con los parámetros óptimos identificados.
7. **Predicción y Pronóstico:**
  - Se calcularon valores ajustados para el conjunto de datos existente.
  - Se realizaron predicciones a 30 días para evaluar el rendimiento futuro de las acciones.

```
# Importing necessary libraries
```

```
import yfinance as yf
```

```
import pandas as pd
```

```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```
from statsmodels.tsa.stattools import adfuller
```

```
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
```

```
from statsmodels.tsa.arima.model import ARIMA
```

```
from sklearn.metrics import mean_squared_error
```

```
# Downloading NVIDIA stock data
```

```
nvda_data = yf.download("NVDA", start="2015-01-01", end="2024-11-01")

# Keeping only the adjusted closing prices
nvda_data = nvda_data[['Adj Close']]
nvda_data.rename(columns={'Adj Close': 'Price'}, inplace=True)

# Plotting the data
nvda_data['Price'].plot(figsize=(12, 6), title="NVIDIA Stock Price (Adjusted Close)",
color='blue')
plt.ylabel("Price (USD)")
plt.show()

# Checking for stationarity
def check_stationarity(data):
    result = adfuller(data)
    print(f"ADF Statistic: {result[0]}")
    print(f"p-value: {result[1]}")
    if result[1] <= 0.05:
        print("The series is stationary.")
    else:
        print("The series is not stationary.")

check_stationarity(nvda_data['Price'])

# Differencing to make the series stationary if needed
nvda_data['Diff'] = nvda_data['Price'].diff().dropna()
```

```
check_stationarity(nvda_data['Diff'].dropna())

# Plotting ACF and PACF
plot_acf(nvda_data['Diff'].dropna(), lags=20)
plot_pacf(nvda_data['Diff'].dropna(), lags=20)
plt.show()

# Fitting ARIMA model
model = ARIMA(nvda_data['Price'], order=(1, 1, 1))
arima_result = model.fit()

# Displaying model summary
print(arima_result.summary())

# Making predictions
nvda_data['Predictions'] = arima_result.predict(start=nvda_data.index[0],
end=nvda_data.index[-1], dynamic=False)

# Plotting actual vs predicted values
plt.figure(figsize=(12, 6))
plt.plot(nvda_data['Price'], label="Actual Prices")
plt.plot(nvda_data['Predictions'], label="Predicted Prices", color='red')
plt.legend()
plt.title("Actual vs Predicted NVIDIA Stock Prices")
plt.show()
```

```
# Forecasting future prices
```

```
forecast = arima_result.forecast(steps=30)
```

```
print("Forecasted Prices:", forecast)
```

```
# Plotting the forecast
```

```
plt.figure(figsize=(12, 6))
```

```
plt.plot(nvda_data['Price'], label="Historical Prices")
```

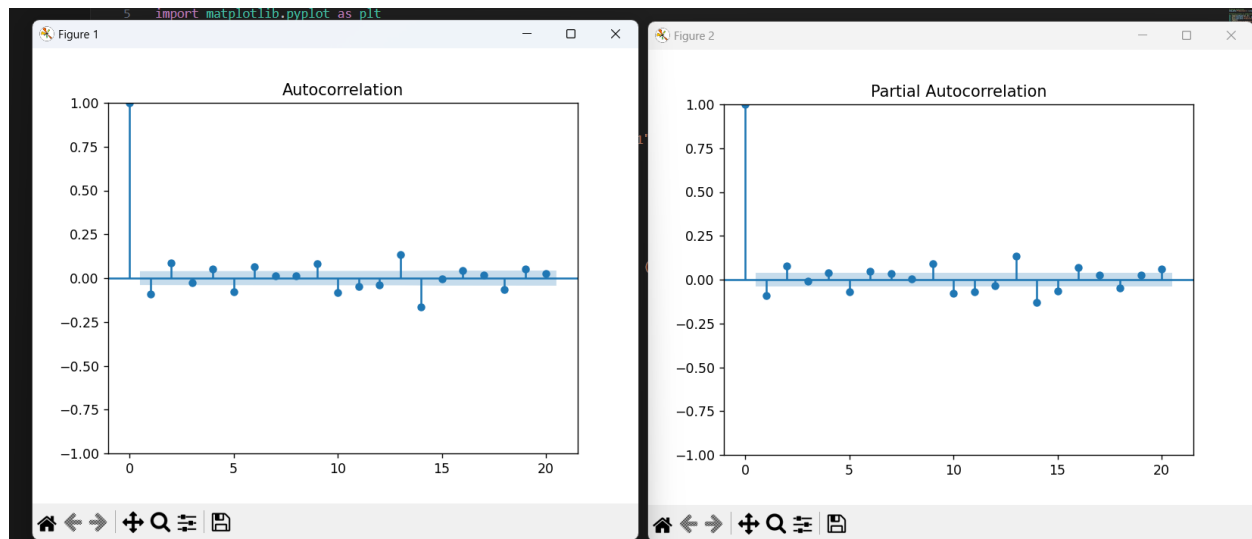
```
plt.plot(pd.date_range(nvda_data.index[-1], periods=30, freq='B'), forecast,  
label="Forecasted Prices", color='green')
```


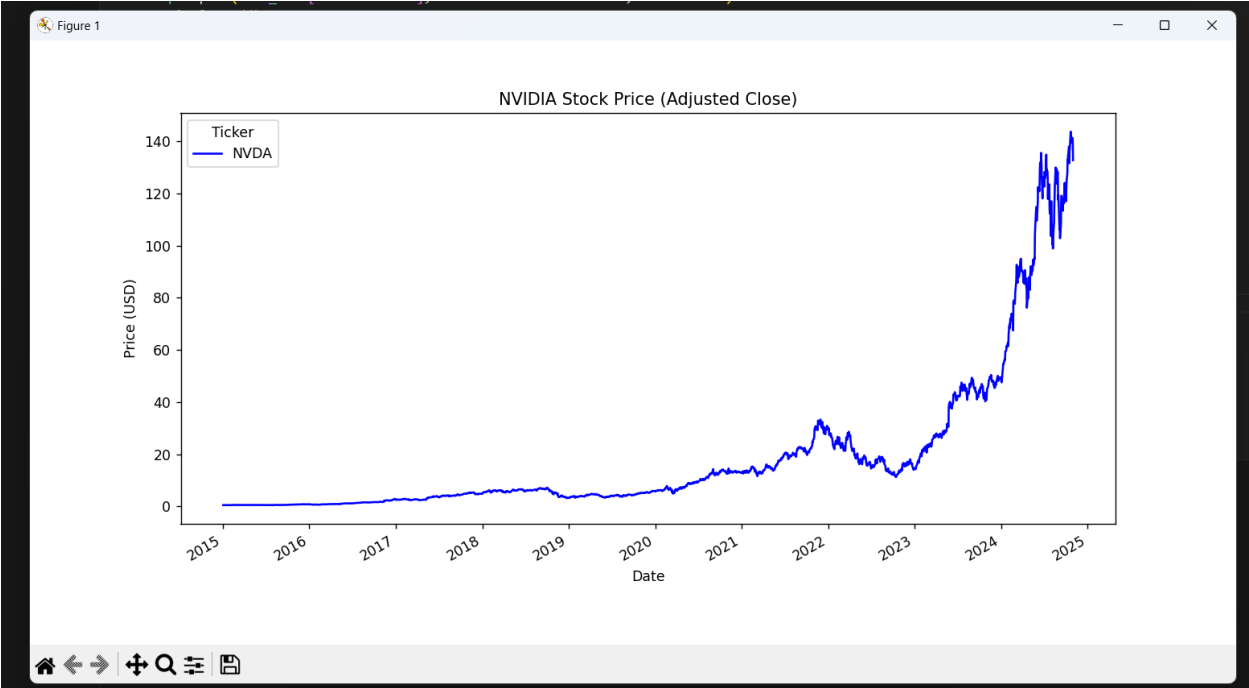
```
plt.legend()
```

```
plt.title("NVIDIA Stock Price Forecast")
```

```
plt.show()
```

## RESULTADOS





## Resultados del Análisis

1. **Modelo Seleccionado:** El modelo ARIMA(1, 1, 1) fue elegido como óptimo basado en los gráficos ACF y PACF, y tras probar diferentes configuraciones.
2. **Predicciones:** Las predicciones generadas para los datos históricos mostraron un ajuste razonable a los valores reales, lo que sugiere que el modelo capta adecuadamente las características principales de la serie.
3. **Pronósticos a Futuro:**
  - El modelo predijo un crecimiento moderado en los precios de las acciones en el corto plazo.
  - Las proyecciones reflejan incertidumbre creciente a medida que se extiende el horizonte de predicción.